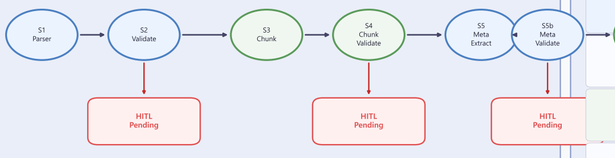
KMS 파이프라인 아키텍처 (LangGraph 기반 Agentic AI Workflow)

AI Agent 기반 문서 정제 파이프라인 (HITL + Harness Engineering 포함)



LangGraph 구조 (StateGraph)



총 8개 노드 • Conditional Edge 3개 (Stage 2 / 4 / 5b)

HITL 분기 3지점 • 실패 시 END • 성공 시 다음 Stage

Agent Node (LLM) Tool Node Workflow Node End

Agent / Tool / Workflow Node 구분

노드명	분류	모델	역할 요약
DocumentParserAgent	Agent	Gemini 2.5 Flash	파일 복잡도 판단, 최적 파서 선택, Markdown 변환
MarkdownValidateAgent	Agent	Gemini 2.5 Flash	Markdown 품질 점수화, 자동 수정/재시도
ChunkingTool	Tool	—	Header 기반 Parent-Child 청크 생성
ChunkValidateTool	Tool	—	청크 크기, 연결, 토큰 범위 검증
MetadataExtractAgent	Agent	Gemini 2.5 Flash	메타데이터(title/category/tags/entities) 추출
MetadataValidateAgent	Agent	Gemini 2.5 Flash	메타데이터 정확도 2차 검증 (점수화)
StoreRouteTool	Tool	bge-m3 / OpenAI small*	임베딩 + 4개 스토리지 멀티 저장
hitl_pending	Workflow	—	HITL 큐 INSERT 및 파이프라인 중단 제어

* StoreRouteTool: child chunk ≤ 50 → bge-m3, > 50 → OpenAI text-embedding-3-small (1024dim)

Trace & Observability (Harness Engineering + LangSmith)

trace_id 생성

new_pipeline_trace(stage, doc_id)

형식: trc_0001_{doc_id_8hex}

agent_traces 테이블 (PostgreSQL)

trace_id • agent_name • doc_id

status (running / success / fail)

started_at / ended_at / execution_ms

error_message (if any)

LangSmith 연동 (선택적)

LANGCHAIN_TRACING_V2=true 설정 시 자동 전송

대시보드 trace_id 검색/조회 가능

[v] 모든 Agent 실행 추적

[v] 실행 시간/성공·실패 기록

[v] 재현성 및 디버깅 지원

[v] LangSmith 대시보드 조회 가능

HITL (Human-in-the-Loop) + 저장 구조

[v] 품질 기준 미달 시 자동 HITL 분기

[v] Human Review에서 수정/보완 후 승인

[v] 승인 시 해당 Stage 재처리 후 재개

[v] 모든 재처리도 trace_id로 추적

HITL 발동 기준 (3지점)

1. Stage 2 (Markdown 검증)

quality_score < 0.65 (PDF) / < 0.80 (기타)

2. Stage 4 (Chunk 검증)

토큰 범위 초과 또는 Parent-Child 연결 실패

3. Stage 5b (Metadata 검증)

metadata_score < 0.70

저장 구조 (멀티 스토리지)

PostgreSQL

메타데이터
(documents, chunks)

pgVector

벡터 저장
(임베딩 검색)

GCS/Local

파일 저장
(원본, Markdown)

Neo4j GraphDB

관계 저장
(Entity, 그래프 탐색)

→ RAG 검색 (pgVector) + 그래프 탐색 (Neo4j) + 원본 접근 (Storage)